MINISTERUL EDUCAȚIEI
UNIVERSITATEA TEHNICĂ
DIN CLUJ-NAPOCA
FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE

AMERICAN SIGN LANGUAGE LETTER RECOGNITION

PROIECT DE SEMESTRU

Student: **Diana – Gabriela RANF**

Disciplina: **Sisteme bazate pe Cunoaștere**

2026

Cuprins

1 INTRODUCERE 3

1.1 CONTEXT GENERAL 3
1.2 OBIECTIVE 4
1.2.1 Realizarea unui model de predicție 4
1.2.2 Utilizarea rețelelor neuronale convoluționale (CNN) 4
1.2.3 Testarea și evaluarea modelului 4
1.2.4 Aplicabilitatea în lumea reală 5
1.3 SPECIFICAȚII 5
1.3.1 Principalele funcții ale aplicației 5
1.3.2 Interfața aplicației: 5
1.3.3 Performanța modelului: 6
1.3.4 Calitatea aplicației și limitările acesteia 6

2 CUNOAȘTEREA ȘI ANALIZA SETULUI DE DATE 7

2.1 PROVOCAREA GĂSIRII UNUI SET DE DATE ADECVAT 7
2.2 CONSTRUIREA PROPRIULUI SET DE DATE 7
2.3 REALIZAREA UNOR MOSTRE REPREZENTATIVE 8
2.4 ETAPE DE VERIFICARE A CALITĂȚII DATELOR: 9
2.4.1 Detectarea imaginilor duplicate 9
2.4.2 Detectarea imaginilor corupte 9
2.5 CARACTERISTICILE SETULUI DE DATE 9

3 PRE-PROCESAREA SETULUI DE DATE 10

3.1 METODE APLICATE PENTRU PREPROCESAREA DATELOR 10
3.1.1 Eliminarea zgomotului și filtrarea imaginilor 10
3.1.2 Normalizare 10
3.1.3 Redimensionare 10
3.1.4 Augmentarea datelor 10
3.2 IMPARTIREA SETULUI DE DATE: ANTRENARE, VALIDARE, TESTARE 11
3.2.1 Setul de antrenare (Train – 70%) 11
3.2.2 Setul de validare (Validation – 15%) 11
3.2.3 Setul de testare (Test – 15%) 11
3.3 REZULTATELE PRE-PROCESĂRII 12

4 MODELAREA SISTEMULUI 13

4.1 INTRODUCERE IN MODELAREA SISTEMULUI 13
4.2 RETELE NEURONALE CONVOLUTIONALE (CNN) 13
4.3 MODELUL SECVENTIAL (SEQUENTIAL) SI COMPONENTELE SALE 13
4.3.1 Straturi Convoluționale (Conv2D) 13
4.3.2 Straturi de Activare (ReLU) 14
4.3.3 Straturi de Pooling (MaxPool2D) 14
4.3.4 Straturi de Normalizare (BatchNormalization) 14
4.3.5 Flattening 14
4.3.6 Straturi Complet Conectate (Dense) 14
4.3.7 Stratul de Ieșire (Dense) 14
4.4 COMPILAREA MODELULUI: 15
4.5 MEDIU DE IMPLEMENTARE 15

4.5.1 Bibliotecile utilizate ... 15
4.6 MODUL DE PREZENTARE ... 16
4.7 EVALUAREA MODELULUI ... 16
4.7.1 Implementarea unei functii „random_testing” ... 16
4.7.2 Grafice cu privire la „Accuracy” si „Loss” ... 17
4.7.3 Matricea de confuzie ... 17
4.7.4 Acurateţe per clasă ... 18
4.8 REZULTATE EXPERIMENTALE ... 18
5 CONCLUZII ... 19
5.1 REZULTATE OBŢINUTE ... 19
5.2 DIRECŢII DE DEZVOLTARE ... 19
6 BIBLIOGRAFIE ... 20

1 Introducere

1.1 Context general

Comunicarea eficientă este una dintre nevoile fundamentale ale oamenilor de pretutindeni, iar lipsa acesteia poate genera obstacole semnificative în viața personală și profesională. Persoanele cu deficiențe de vorbire se confruntă adesea cu dificultăți în transmiterea mesajelor și participarea activă la interacțiuni cotidiene sau la întâlniri, ședințe online.

Proiectul realizat se concentrează pe detectarea în timp real a literelor limbajului semnelor american (ASL), folosind limbajul de programare Python și rețele neuronale convoluționale (CNN). Dorința de a crea o metodă accesibilă și rapidă prin care persoanele cu deficiențe de vorbire să poată comunica mai ușor, inclusiv în medii digitale, este motivația proiectului. Deși lucrarea se limitează doar la recunoașterea literelor, scopul pe termen lung este extinderea acesteia la recunoașterea întregului limbaj de semne.

Din punct de vedere social, proiectul contribuie la integrarea persoanelor cu dizabilități în comunitate și la facilitarea participării lor active în diverse contexte. Din perspectiva tehnologică, proiectul demonstrează modul în care inteligența artificială, în special CNN-urile, pot fi aplicate pentru recunoașterea și interpretarea gesturilor.

În primul capitol se prezintă contextul teoretic, obiectivele alese și specificațiile necesare. Al doilea capitol detaliază realizarea setului de date, urmând ca în cel de-al treilea capitol să fie descris modul în care datele au fost preprocesate. Capitolul patru este dedicat modelării aplicației, mai exact implementării și testării. Ultimul capitol analizează rezultatele obținute și propune direcții de dezvoltare viitoare pentru extinderea aplicației la întregul limbaj ASL. Este inclusă, de asemenea, o bibliografie care menționează sursele.

Un aspect important al proiectului constă în optimizarea performanței modelului CNN pentru recunoașterea semnelor în timp real. Aceasta implică nu doar antrenarea rețelei pe un set de date adecvat, ci și ajustarea parametrilor, a ratei de învățare și a numărului de epoci pentru a obține o acurateță cât mai mare. Prin punerea în valoare a tehnologiilor de inteligență artificială în scopuri sociale, proiectul evidențiază modul în care inovațiile tehnologice pot contribui la reducerea barierelor de comunicare și la creșterea accesibilității, mediul devenind unul mai incluziv.

În plus, proiectul implica cunoștințe din numeroase categorii precum inteligența artificială, procesarea de imagini, gestionarea corespunzătoare a unui set de date și multe altele. Astfel, proiectul combină atât impactul social, cât și cel educațional și tehnologic, demonstrând potențialul inteligenței artificiale de a genera soluții practice și utile în viața de zi cu zi.

1.2 Obiective

Proiectul îşi propune să creeze o soluţie inovativă care să contribuie la îmbunătăţirea comunicării interpersonale, care facilitează integrarea persoanelor cu dizabilităţi în societate. Prin intermediul acestei aplicaţii, utilizatorii vor putea comunica mai uşor cu persoanele care utilizează limbajul semnelor, oferind astfel un instrument util atât în context educaţional, cât şi în viaţa de zi cu zi. Impactul social al proiectului este semnificativ, deoarece tehnologia poate sprijini incluziunea socială.

Pentru realizarea acestei soluţii, proiectul utilizează Reţele Neuronale Convoluţionale (CNN – Convolutional Neural Networks), care sunt un tip special de reţele neuronale artificiale optimizate pentru procesarea imaginilor. CNN-urile sunt capabile să înveţe caracteristici relevante din imagini, fără a fi necesară extragerea manuală a acestora. Astfel, prin antrenarea modelului cu un set de date care conţine imagini ale semnelor limbajului ASL (American Sign Language), aplicaţia va fi capabilă să recunoască semnele în timp real şi să afişeze litera corespunzătoare împreună cu procentul de încredere, indicând cât de sigur este modelul de predicţia sa.

1.2.1 Realizarea unui model de predicţie

Primul pas în dezvoltarea aplicaţiei este construirea unui model de predicţie eficient. Aceasta presupune definirea arhitecturii reţelei neuronale, selectarea parametrilor optimi şi pregătirea setului de date pentru antrenare. Scopul acestui model este de a putea transforma informaţia vizuală (imagini ale semnelor) în date interpretabile (literele alfabetului ASL), oferind utilizatorului un răspuns rapid şi precis.

1.2.2 Utilizarea reţelelor neuronale convoluţionale (CNN)

CNN-urile reprezintă nucleul tehnologic al proiectului. Aceste reţele sunt concepute special pentru recunoaşterea tiparelor în imagini, folosind straturi convoluţionale care extrag automat caracteristicile importante. Prin antrenarea reţelei pe un volum mare de imagini, modelul devine capabil să identifice semnele limbajului ASL chiar şi în condiţii variate, cum ar fi diferenţe de iluminare sau unghiuri diferite ale mâinii.

1.2.3 Testarea şi evaluarea modelului

După antrenarea reţelei, este esenţială testarea acesteia pentru a verifica acurateţea şi fiabilitatea predicţiilor. Această etapă implică evaluarea modelului pe un set de date separat de cel folosit la antrenare şi calcularea metricilor de performanţă, cum ar fi acurateţea, precizia şi scorul F1. Testarea riguroasă asigură că modelul poate fi utilizat în situaţii reale, oferind rezultate consistente şi corecte.

1.2.4 Aplicabilitatea în lumea reală

Ultimul obiectiv este de o importanta majora si urmăreşte integrarea practică a aplicaţiei în mediul cotidian. Recunoaşterea semnelor în timp real poate fi utilizată nu doar pentru comunicarea între persoane cu dizabilităţi auditive şi restul societăţii, ci şi în educaţie, în centre de instruire pentru limbajul semnelor sau chiar în aplicaţii mobile care facilitează traducerea automată a semnelor. Această componentă evidenţiază valoarea socială şi utilitatea practică a proiectului.

Prin atingerea acestor obiective, proiectul nu doar că explorează şi aplică tehnici avansate de inteligenţă artificială, dar contribuie şi la crearea unui instrument cu impact social real, sprijinind incluziunea şi comunicarea eficientă între oameni.

1.3 Specificaţii

În cadrul acestei lucrări sunt definite o serie de specificaţii care stabilesc cerinţele sistemului propus, precum şi performanţele aşteptate ale aplicaţiei. Scopul principal este dezvoltarea unei aplicaţii capabile să recunoască în timp real literele limbajului semnelor american (ASL), utilizând un model bazat pe reţele neuronale convoluţionale (CNN), integrat într-o interfaţă accesibilă şi intuitivă.

1.3.1 Principalele funcţii ale aplicaţiei

- Captarea imaginilor în timp real prin intermediul camerei web, folosind biblioteci specifice din Python (ex. OpenCV).
- Preprocesarea imaginilor, care include redimensionarea, augmentarea si aplicarea unui filtru (filtrul median)
- Încărcarea şi utilizarea modelului CNN antrenat, capabil să clasifice imaginile în funcţie de literele alfabetului ASL.
- Afişarea predicţiei în timp real dupa ce s-a realizat fotografia, incluzând: litera detectată; procentul de încredere (probabilitatea asociată predicţiei).

1.3.2 Interfaţa aplicaţiei:

Interfaţa aplicaţiei este concepută pentru a fi simplă şi intuitivă, astfel încât utilizatorul să poată interacţiona cu sistemul fără dificultăţi. Designul interfeţei urmăreşte principiile de claritate şi accesibilitate, evitând supraîncărcarea vizuală şi asigurând lizibilitatea informaţiilor afişate.

Aceasta trebuie să includă:

- fereastra video cu imaginea captată în timp real;
- chenarul unde trebuie realizata litera din alfabetul ASL
- afişarea clară a literei prezise;
- afişarea procentului de încredere;
- posibilitatea de închidere controlată a aplicaţiei.

1.3.3 Performanţa modelului:

Criterii de performanţă:

- Acurateţe ridicată a modelului, ideal peste 90% pe setul de test.
- Timp de răspuns redus, astfel încât predicţia să fie realizată aproape instantaneu (procesare în timp real).
- Stabilitate în condiţii variate de iluminare şi poziţionare a mâinii.
- Consum rezonabil de resurse hardware (CPU/GPU şi memorie RAM).

1.3.4 Calitatea aplicaţiei şi limitările acesteia

Calitatea aplicaţiei este determinată de precizia modelului şi de stabilitatea funcţionării în timp real. Totuşi, există anumite limitări:

- recunoaşterea este limitată iniţial la literele alfabetului ASL
- performanţa poate fi influenţată de condiţiile de iluminare sau de fundal;
- aplicaţia nu interpretează componente non-manuale ale limbajului semnelor.
- aplicaţia nu interpretează literele alfabetului care se realizează prin mişcarea mâinii precum litera „ J ”
- În viitor, sistemul poate fi extins pentru a recunoaşte gesturi dinamice şi propoziţii complete, precum şi pentru a integra un modul de conversie text-voce.

2 Cunoaşterea şi analiza setului de date

2.1 Provocarea găsirii unui set de date adecvat

Întrucât proiectul propus nu a făcut parte din lista temelor predefinite, nu a fost pus la dispoziţie un set de date standard. În etapa iniţială, am analizat mai multe seturi de date disponibile public, în special pe platforma Kaggle, care oferă colecţii extinse de imagini pentru recunoaşterea limbajului semnelor american (ASL). Unul dintre seturile analizate conţinea aproximativ 8000 de imagini pentru fiecare literă a alfabetului.

Cu toate acestea, utilizarea acestui set de date s-a dovedit nepractică din două motive principale. În primul rând, limitările hardware ale laptopului utilizat (resurse CPU/GPU şi memorie RAM) ar fi condus la timpi de antrenare foarte mari. În al doilea rând, analiza vizuală preliminară a evidenţiat o calitate neuniformă a imaginilor: iluminare slabă, fundaluri complexe, prezenţa altor persoane în cadru şi elemente irelevante pentru obiectivul proiectului.

2.2 Construirea propriului set de date

În cadrul aplicaţiei dezvoltate, utilizatorul realizează semnul ASL într-un chenar delimitat, cu fundal simplu şi focalizare exclusivă pe poziţia mâinii. Din acest motiv, a fost considerat mai adecvat un set de date controlat, adaptat exact condiţiilor de utilizare ale aplicaţiei. Prin urmare, am decis construirea unui set de date propriu, alcătuit din aproximativ 200 de imagini pentru fiecare literă a alfabetului ASL. Această abordare a oferit mai multe avantaje:

- control total asupra calităţii imaginilor
- fundal uniform şi lipsit de elemente perturbatoare (este un posibil dezavantaj daca modelul este testat in conditii nefavorabile)
- iluminare constantă
- poziţionare clară a mâinii în cadrul delimitat;
- posibilitatea de a învăţa şi exersa personal semnele ASL

Fiecare subfolder conţine imaginile asociate unei litere. Numărul de imagini per clasă/literă este de aproximativ 200 imagini, ceea ce conduce la un set de date relativ echilibrat. Distribuţia imaginilor pe clase a fost analizată prin reprezentare grafică (diagramă de tip bar chart). Rezultatele au arătat că variaţiile între clase sunt minime, reducând riscul apariţiei unui bias în procesul de antrenare al modelului, dezechilibrul claselor fiind un factor major care poate afecta performanţa clasificatorilor motiv pentru care menţinerea unui dataset echilibrat este esenţială. Toate imaginile au fost redimensionate la rezoluţia 64×64 pixeli pentru a asigura consistenţa intrării în reţeaua neuronală convoluţională. Pentru o înţelegere profundă a caracteristicilor vizuale ale datelor, au fost realizate mai multe analize grafice.

2.3 Realizarea unor mostre reprezentative

Mostre reprezentative din fiecare clasă afisate pentru a analiza:

- variaţia poziţiei mâinii
- unghiul de realizare a semnului
- variaţii minore ale orientării degetelor
- consistenţa fundalul

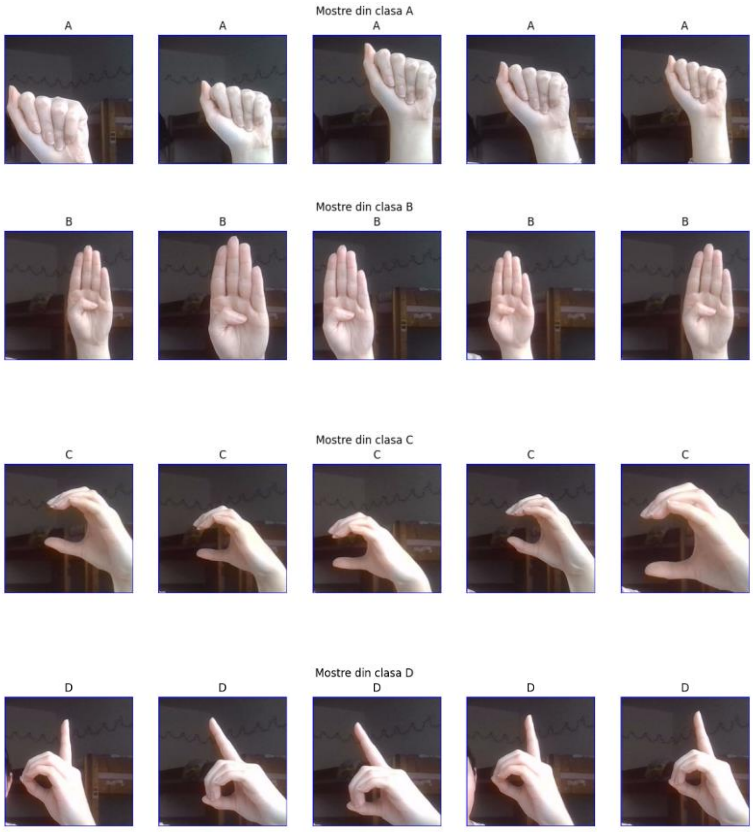

Figura 2.1. Mostre reprezentative pentru analiza setului de date

Analiza vizuală a confirmat existenţa unei diversităţi suficiente în poziţionarea mâinii, ceea ce este benefic pentru capacitatea modelului de generalizare. În acelaşi timp, fundalul controlat reduce zgomotul inutil din imagine, concentrând procesul de învăţare asupra formei mâinii.

2.4 Etape de verificare a calităţii datelor:

2.4.1 Detectarea imaginilor duplicate

A fost utilizată o metodă de hashing (MD5) pentru identificarea imaginilor identice. Această etapă este importantă deoarece duplicatele pot conduce la supraînvăţare (overfitting), modelul memorând imagini repetitive în loc să învețe caracteristici generalizabile. În urma analizei, nu au fost identificate duplicate semnificative în cadrul setului de date.

2.4.2 Detectarea imaginilor corupte

Integritatea imaginilor a fost verificată utilizând metoda verify( ) din biblioteca Pillow. Această verificare asigură faptul că toate fişierele pot fi citite şi procesate fără a produce erori în timpul antrenării modelului. Nu au fost identificate fişiere corupte.

2.5 Caracteristicile setului de date

- distribuţie echilibrată a claselor
- imagini curate, cu fundal simplu
- iluminare controlată
- lipsa duplicatelor şi a fişierelor corupte
- consistenţă dimensională

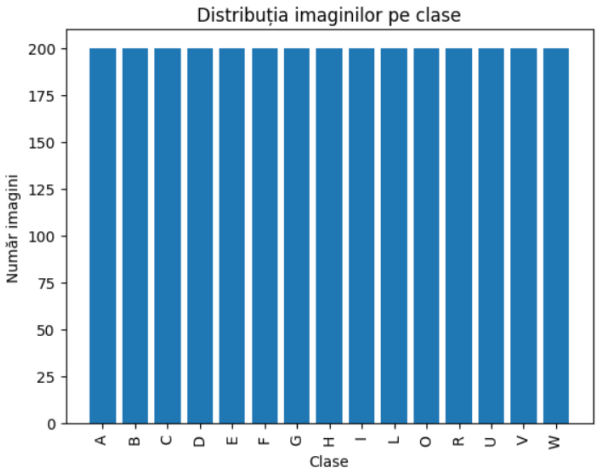

Figura 2.2. Dataset-ul echilibrat cu 200 imagini per litera

Deşi dimensiunea datasetului este mai redusă comparativ cu seturile publice disponibile, controlul asupra calităţii imaginilor şi adaptarea lor la scenariul real al aplicaţiei reprezintă un avantaj major. În literatura de specialitate se subliniază faptul că relevanţa şi calitatea datelor pot avea un impact mai mare asupra performanţei modelului decât simpla cantitate a acestora.

Observatie: Unele litere ale alfabetului constau în mişcarea mâinii, funcţionalitate pe care acest proiect nu o îndeplineşte, motiv pentru care sunt doar 15 litere reprezentate.

3 Pre-procesarea setului de date

Pre-procesarea datelor este o etapă esențială în construirea unui model de învățare profundă, în special atunci când lucrăm cu imagini, unde calitatea datelor poate influența semnificativ performanța modelului. În cazul acestui proiect, setul de date a fost construit manual și conține aproximativ 200 de imagini pentru fiecare literă a alfabetului ASL. Obiectivul pre-procesării a fost reducerea zgomotului, standardizarea dimensiunilor și îmbunătățirea diversității imaginilor pentru a permite modelului să generalizeze corect.

3.1 Metode aplicate pentru preprocesarea datelor

3.1.1 Eliminarea zgomotului și filtrarea imaginilor

Pentru a reduce zgomotul din imagini și a păstra detaliile relevante ale mâinii a fost aplicat un filtru median. Acesta reduce zgomotul de tip impuls fără a estompa marginile semnificative ale mâinii. Acest filtru inlocuiește fiecare punct de date cu mediana punctelor învecinate. Eficient pentru eliminarea zgomotului „salt-and-pepper”, contribuind la netezirea imaginilor.

3.1.2 Normalizare

Toate imaginile au fost normalizate, astfel încât valorile pixelilor să fie scalate între valorile [-1 ; 1]. Această abordare permite rețelelor neuronale să convergă mai rapid și să învețe mai eficient caracteristicile vizuale. Scopul principal al normalizării este de a reduce diferențele mari între valorile pixelilor și de a aduce toate imaginile la aceeași scară numerică, ceea ce facilitează procesul de învățare al modelului.

3.1.3 Redimensionare

Imaginile inițiale aveau dimensiuni variabile. Pentru a fi compatibile cu arhitectura CNN (rețeaua așteaptă intrări cu aceeași dimensiune și număr de canale pentru a putea aplica filtrele convoluționale și operațiile de pooling în mod uniform) și pentru a menține consistența datasetului, toate imaginile au fost redimensionate la 64×64 pixeli.

3.1.4 Augmentarea datelor

Pentru a crește diversitatea datasetului și a preveni supraînvățarea, au fost aplicate tehnici de augmentare doar pe setul de antrenament ce constau în generarea artificială de noi exemple prin aplicarea unor transformări asupra imaginilor originale. Astfel, modelul va fi capabil să recunoască semne ASL chiar și când poziția, dimensiunea sau iluminarea mâinii diferă de imaginile din setul de antrenament:

- Flip pe orizontală – simulează poziții diferite ale mâinii în cadru.
- Rotire aleatorie mică (±10%) – permite modelului să recunoască semnele chiar dacă mâna nu este perfect dreaptă.
- Zoom aleatoriu (±10%) – simulează apropierea sau depărtarea mâinii de cameră.
- Translație aleatorie (±10%) – modifică poziția mâinii în cadru.
- Ajustarea contrastului – atenuează efectele variațiilor de iluminare.
- Crop aleatoriu – creează mici variații ale poziției mâinii în cadrul fix de 64×64 pixeli.

3.2 Impartirea setului de date: Antrenare, Validare, Testare

3.2.1 Setul de antrenare (Train – 70%)

Setul de antrenare un procentaj de imagini de 70% din setul de date și este folosit de model pentru învățarea efectivă a caracteristicilor vizuale ale literelor ASL.

3.2.2 Setul de validare (Validation – 15%)

- Este utilizat pentru a monitoriza performanța modelului în timpul antrenării, fără ca imaginile din acest set să fie folosite pentru actualizarea greutăților.
- Permite detectarea fenomenului de overfitting, adică atunci când modelul se adaptează prea mult la imaginile de antrenament și pierde capacitatea de generalizare.
- În funcție de metricile calculate pe setul de validare (precizie, pierdere), se pot ajusta hiperparametrii modelului (learning rate, număr de epoci etc.).

3.2.3 Setul de testare (Test – 15%)

- Este folosit doar după antrenarea completă a modelului, pentru a evalua performanța reală și capacitatea de generalizare a rețelei.
- Acest set oferă o estimare obiectivă a cât de bine va recunoaște modelul semnele ASL în situații noi, neîntâlnite anterior.

3.3 Rezultatele pre-procesării

Ca urmare a pre-procesării, setul de date prezintă următoarele caracteristici:

- Fundal uniform și lipsa zgomotului vizual semnificativ
- Poziții și orientări variate ale mâinii în cadrul chenarului
- Set de antrenare diversificat prin augmentare, crescând capacitatea de generalizare a modelului

Figura 3.1. Rezulatul pre-procesarii

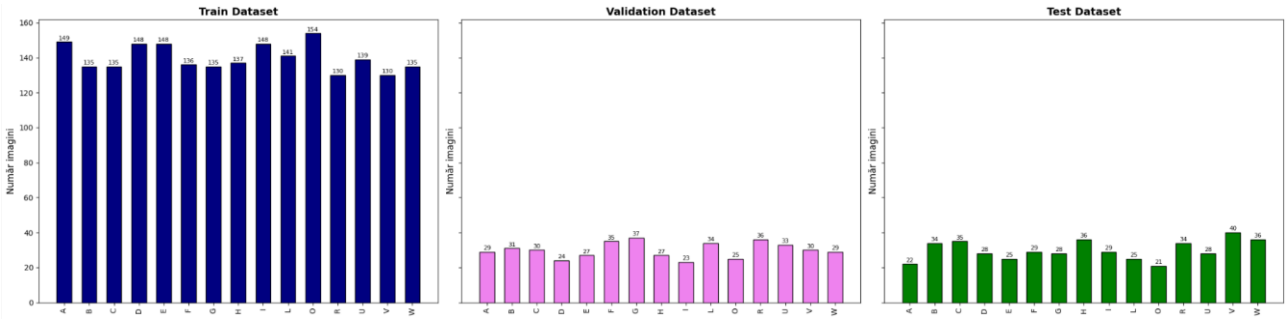

Figura 3.2. Split-ul datasetului

4 Modelarea sistemului

4.1 Introducere in modelarea sistemului

Sistemul este conceput pentru recunoaşterea gesturilor limbajului semnelor (ASL) pe baza imaginilor digitale colectate într-un dataset structurat pe clase. Scopul modelării este de a oferi reţelei informaţii consistente şi relevante, astfel încât aceasta să poată învăţa corect tiparele vizuale asociate fiecărei clase.

Printr-o modelare corespunzătoare, se asigură că datele de intrare respectă dimensiuni standard, scalare adecvată şi reprezentare uniformă a etichetelor. De asemenea, modelarea stabileşte structura dataset-ului pentru a evalua corect performanţa modelului şi a preveni supraînvăţarea. Printr-o prelucrare atentă şi uniformizare a imaginilor, sistemul devine robust şi adaptabil la variaţii naturale ale semnelor. În ansamblu, modelarea sistemului constituie fundamentul pe care se bazează întregul proces de recunoaştere, influenţând direct acurateţea şi eficienţa sistemului final. Proiectul urmareste o abordare bazata pe Deep Learning si pe Retele Neuronale Convolutionale.

4.2 Retele neuronale convolutionale (CNN)

Reţelele neuronale convoluţionale (CNN) sunt un tip de arhitectură deep learning special concepută pentru procesarea imaginilor. Ele sunt capabile să extragă automat caracteristici relevante, cum ar fi margini, texturi şi forme, şi să recunoască tipare complexe chiar şi în prezenţa variaţiilor de poziţie, scară sau iluminare. CNN-urile includ straturi convoluţionale, straturi de pooling şi straturi complet conectate, care lucrează împreună pentru a transforma imaginile brute în predicţii precise. Ele scanează datele local, învăţând ierarhii spaţiale prin concentrarea pe pixelii apropiaţi. Una dintre aplicatiile principale ale CNN-urilor constau in clasificarea imaginilor: identificarea si categorisirea obiectelor.

4.3 Modelul Secvential (Sequential) si componentele sale

Modelul foloseşte o reţea neuronală convoluţională (CNN) pentru clasificarea imaginilor limbajului semnelor cu o arhitectura construită secvenţial (Sequential) şi include următoarele componente principale:

4.3.1 Straturi Convoluţionale (Conv2D)

Modelul începe cu un strat convoluţional cu 32 de filtre de dimensiune 3 × 3, urmat de straturi similare cu 64, 128 şi 256 de filtre (in total 4 straturi convolutionale Conv2D). Aceste straturi extrag automat caracteristici locale din imagini, cum ar fi margini, colţuri şi texturi relevante pentru recunoaşterea gesturilor.

4.3.2 Straturi de Activare (ReLU)

Fiecare strat convoluțional folosește funcția de activare ReLU, care introduce non-linearitate. Aceasta permite rețelei să învețe relații complexe și să recunoască forme variate din datele de intrare.

4.3.3 Straturi de Pooling (MaxPool2D)

După fiecare strat convoluțional se aplică Max Pooling, care reduce dimensiunea hărților de caracteristici. Aceasta accelerează calculul, reduce memoria necesară și ajută la prevenirea overfitting-ului prin generalizarea caracteristicilor.

4.3.4 Straturi de Normalizare (BatchNormalization)

După fiecare strat convoluțional și strat dens, se aplică Batch Normalization pentru a stabiliza și accelera antrenarea. Aceasta normalizează valorile activărilor, menținându-le în intervale rezonabile și reducând problemele de tip vanishing/exploding gradients.

4.3.5 Flattening

Hărțile de caracteristici 2D rezultate din ultimele straturi convoluționale sunt transformate într-un vector 1D folosind Flatten. Aceasta pregătește datele pentru straturile complet conectate, care realizează clasificarea finală.

4.3.6 Straturi Complet Conectate (Dense)

Modelul include un strat dens cu 512 neuroni și activare ReLU, urmat de BatchNormalization și Dropout(0.5). Dropout dezactivează aleator 50% dintre neuroni în timpul antrenării, prevenind supraînvățarea.

4.3.7 Stratul de Ieșire (Dense)

Stratul final utilizează activarea Softmax, generând probabilități pentru fiecare clasă din dataset. Aceasta este specifică clasificării multi-clasă și permite modelului să aleagă cea mai probabilă clasă pentru fiecare imagine.

4.4 Compilarea modelului:

Modelul este compilat cu optimizer Adam, loss categorical_crossentropy (deoarece etichetele sunt one-hot encode - metodă de reprezentare a etichetelor categorice într-un format numeric, utilizat frecvent în probleme de clasificare multi-clasă). Fiecare clasă este reprezentată printr-un vector binar de lungime egală cu numărul total de clase, în care:) şi metrică accuracy. Această combinaţie este standard pentru probleme de clasificare multi-clasă şi oferă un bun echilibru între viteză şi performanţă.

4.5 Mediu de implementare

Pentru implementarea proiectului s-a utilizat un mediu de dezvoltare bazat pe Anaconda, cu Jupyter Notebook ca interfaţă principală. Acest mediu a permis gestionarea pachetelor Python şi rularea interactivă a codului, facilitând vizualizarea rezultatelor şi depanarea uşoară.

4.5.1 Bibliotecile utilizate

- os –interacţiunea cu sistemul de fişiere si foldere
- random – permite generarea de valori aleatoare şi selecţia aleatorie a imaginilor
- hashlib – la detectarea imaginilor duplicate.
- pathlib.Path – manipulare a căilor şi fişierelor în sistemul de operare.
- collections.Counter – folosită pentru contorizarea elementelor dintr-o listă
- numpy – bibliotecă fundamentală pentru operaţii numerice
- matplotlib.pyplot – generarea graficelor şi vizualizarea imaginilor şi statisticilor.
- cv2 (OpenCV) – utilizată pentru procesarea imaginilor şi aplicarea de filtre
- tensorflow şi keras – librării pentru dezvoltarea şi antrenarea reţelelor neuronale.
- Sequential – permite definirea modelelor neuronale secvenţiale.
- Conv2D – strat convoluţional pentru extragerea trăsăturilor vizuale.
- MaxPool2D – strat de pooling pentru reducerea dimensiunilor şi a supraînvăţării.
- Dense – strat complet conectat pentru luarea deciziilor finale.
- Dropout – strat de regularizare pentru prevenirea supraînvăţării.
- Flatten – transformă datele 2D în vectori 1D pentru straturile finale.
- BatchNormalization – normalizează activările pentru accelerarea antrenării şi stabilitate.

Acest set de biblioteci şi unelte a fost esenţial pentru procesarea imaginilor, implementarea algoritmilor de deep learning şi vizualizarea rezultatelor într-un mod clar şi academic.

4.6 Modul de prezentare

Modelul este capabil să ruleze live pe cameră, afişând litera recunoscută şi procentul de încredere. Zona de interes (ROI) este marcată cu un chenar pe cadru. Aplicaţia „ASL Detector PRO" rulează live pe cameră şi permite recunoaşterea în timp real a literelor limbajului mimico-gestual (ASL). În fereastra principală, imaginea capturată de cameră este oglindită pentru o vizualizare intuitivă, iar zona de interes (ROI) este evidenţiată printr-un chenar albastru. Utilizatorul poziţionează mâna în interiorul acestui chenar şi apasă tasta „s" pentru a captura o fotografie.

Imaginea este preprocesată automat prin conversie în RGB, redimensionare la 64×64 pixeli, normalizare şi aplicarea unui filtru median. Pe scurt, se aplica aceeasi preprocesare ca in cazul setului de date. Modelul CNN evaluează fotografia şi returnează litera prezisă împreună cu procentul de încredere. Rezultatul este afişat pe ecran, iar culoarea textului indică nivelul de certitudine: verde pentru valori mari, roşu pentru valori mici.

Aplicaţia se actualizează continuu, permiţând testarea rapidă a semnelor. Pentru a opri aplicaţia, utilizatorul apasă tasta „q", ceea ce eliberează camera şi închide fereastra. Această interfaţă oferă un mod simplu şi interactiv de a testa performanţa modelului CNN pentru recunoaşterea literelor ASL.

4.7 Evaluarea modelului

4.7.1 Implementarea unei functii „random_testing"

Funcţia „random_testing" contribuie semnificativ la evaluarea calitativă a performanţei modelului CNN pentru recunoaşterea literelor limbajului ASL. Aceasta permite vizualizarea directă a predicţiilor modelului prin afişarea unui set de 5 imagini selectate aleatoriu din dataset-ul de test. Pentru fiecare imagine, funcţia compară clasa prezisă de model cu clasa reală, evidenţiind astfel corectitudinea predicţiilor într-un mod intuitiv. Prin vizualizarea simultană a imaginii, clasei prezise şi clasei reale, utilizatorul poate observa tiparele de succes sau erorile modelului, identificând eventualele confuzii între clase similare. Funcţia permite astfel o verificare rapidă şi interactivă a capacităţii modelului de generalizare asupra datelor nevăzute anterior.

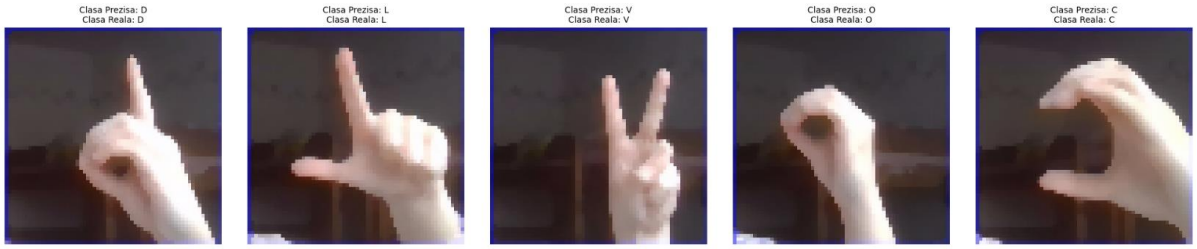

Figura 4.1. Rezultatul funcţiei implementate

4.7.2 Grafice cu privire la „Accuracy” si „Loss”

Graficele generate oferă o reprezentare vizuală clară a evoluției performanței modelului pe parcursul antrenării.

Primul grafic afișează „Accuracy” (acuratețea), comparând performanța pe setul de antrenament și pe setul de validare pentru fiecare epocă. Aceasta permite evaluarea modului în care modelul învață să recunoască corect clasele și evidențiază eventualele probleme de overfitting sau underfitting.

Al doilea grafic prezintă „Loss” (funcția de pierdere), care reflectă cât de bine modelul se apropie de predicțiile corecte; scăderea continuă a acestei valori indică o îmbunătățire a capacității modelului de a se adapta la datele de antrenament.

Împreună, aceste grafice oferă o imagine completă asupra procesului de antrenare. Ele sunt instrumente esențiale pentru analiza și interpretarea comportamentului rețelei neuronale pe parcursul antrenării.

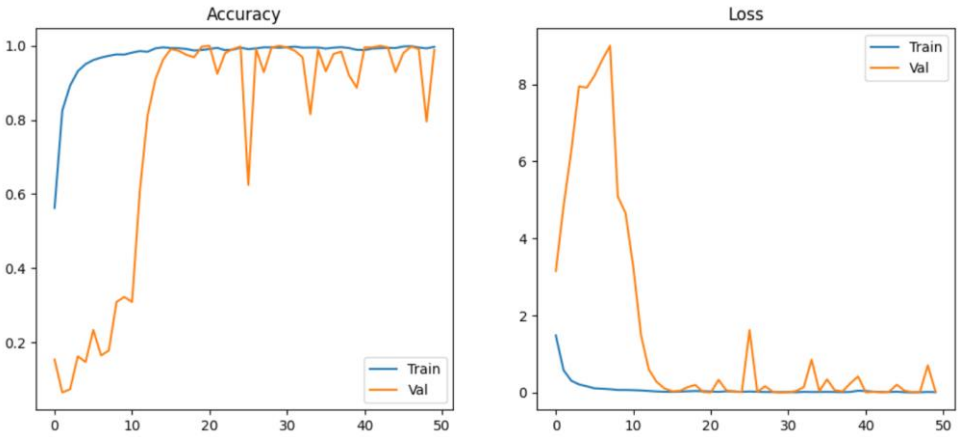

Figura 4.1. Graficul procesului de antrenare

4.7.3 Matricea de confuzie

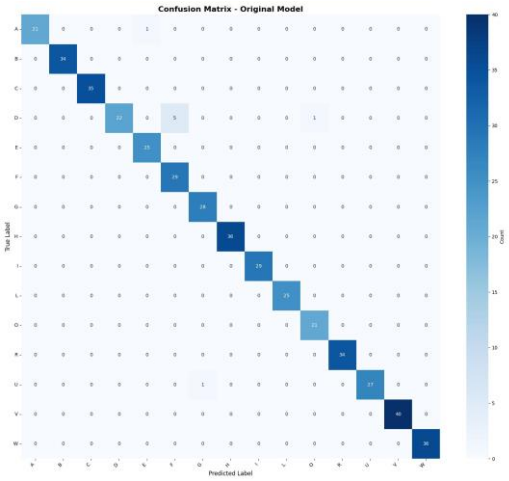

Figura 4.2. Matricea de confuzie

```
Classification Report - Original Model:
==========================================================
              precision    recall  f1-score   support

           A       1.00      0.95      0.98        22
           B       1.00      1.00      1.00        34
           C       1.00      1.00      1.00        35
           D       1.00      0.79      0.88        28
           E       0.96      1.00      0.98        25
           F       0.85      1.00      0.92        29
           G       0.97      1.00      0.98        28
           H       1.00      1.00      1.00        36
           I       1.00      1.00      1.00        29
           L       1.00      1.00      1.00        25
           O       0.95      1.00      0.98        21
           R       1.00      1.00      1.00        34
           U       1.00      0.96      0.98        28
           V       1.00      1.00      1.00        40
           W       1.00      1.00      1.00        36

    accuracy                           0.98       450
   macro avg       0.98      0.98      0.98       450
weighted avg       0.98      0.98      0.98       450
```

Figura 4.3.Classification Raport

4.7.4 Acurateţe per clasă

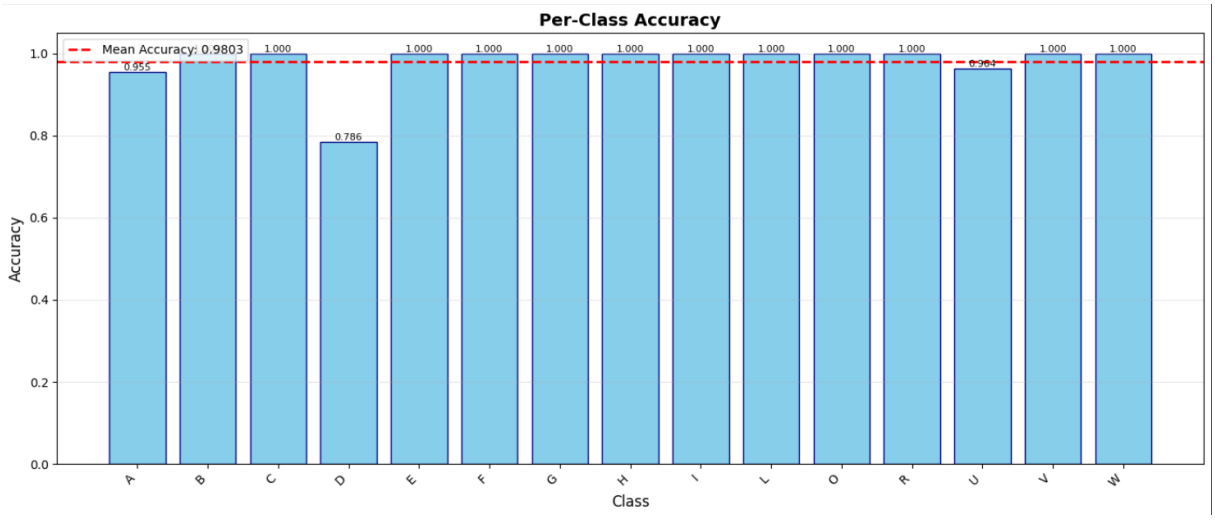

Figura 4.4. Acurateţea per clasă

4.8 Rezultate experimentale

Graficul procesului de antrenare subliniază faptul ca antrenarea se realizează în 50 de epoci, modelul reuşind să înveţe mai bine şi să aibă o validare mai bună începând cu epoca 15.

Matricea de confuzie indică faptul că anumite litere se confundă una cu cealaltă datorită similarităţii semnului. Un exemplu concret este litera “D” care este aproximativ la fel cu litera „O”. Din aceasta cauză se poate observa şi în tabelul de clasificare şi în acurateţea per clasă faptul că litera „D” nu are o predicţie atât de puternică.

5 Concluzii

5.1 Rezultate obţinute

În urma antrenării modelului de clasificare a literelor din limbajul semnelor, s-a obţinut o acurateţe globală de 98% pe setul de testare, demonstrând o capacitate ridicată de generalizare. Metricile Precision, Recall şi F1-score au înregistrat valori apropiate de 1 pentru majoritatea claselor, indicând o performanţă stabilă şi echilibrată. Clasele precum B, C, H, I, L, R, V şi W au fost clasificate perfect, fără erori semnificative. Cele mai mari dificultăţi au fost întâmpinate la literele D şi F, unde au apărut uşoare confuzii, probabil din cauza similarităţilor vizuale dintre gesturi.

Din punct de vedere al aplicabilităţii practice, sistemul dezvoltat poate reprezenta baza unui instrument software capabil să faciliteze comunicarea dintre persoanele auzitoare şi cele cu deficienţe de auz. În viaţa de zi cu zi, o astfel de aplicaţie ar putea fi utilizată în instituţii publice, unităţi medicale, şcoli sau în mediul online, pentru traducerea rapidă a gesturilor în text. De asemenea, poate avea un rol educaţional, sprijinind procesul de învăţare a alfabetului în limbajul semnelor prin feedback automat şi corectarea greşelilor. Astfel, rezultatele obţinute demonstrează nu doar performanţa tehnică a modelului, ci şi potenţialul său real de integrare în soluţii digitale cu impact social.

5.2 Direcţii de dezvoltare

O direcţie importantă de dezvoltare constă în extinderea sistemului pentru recunoaşterea unui număr mai mare de semne din limbajul mimico-gestual, incluzând nu doar literele alfabetului, ci şi cifre, cuvinte uzuale şi expresii frecvente. O îmbunătăţire majoră ar fi integrarea recunoaşterii dinamice a gesturilor, folosind secvenţe video şi modele de tip CNN-LSTM sau Transformers pentru captarea mişcării în timp.

De asemenea, sistemul poate fi extins pentru a analiza expresiile faciale, care joacă un rol esenţial în transmiterea sensului în limbajul semnelor. Integrarea recunoaşterii feţei şi a emoţiilor ar permite o interpretare mai fidelă a mesajului complet. O altă direcţie ar fi dezvoltarea unei interfeţe grafice interactive, destinată utilizatorilor finali, care să permită recunoaştere în timp real prin cameră web şi afişarea traducerii textuale instant.

Se poate implementa şi un modul de conversie text-în-semn, pentru a facilita comunicarea bidirecţională între persoane auzitoare şi persoane cu deficienţe de auz. În plus, crearea unui dataset mai divers, cu variaţii mai mari de iluminare, fundal şi utilizatori diferiţi, ar contribui la creşterea robusteţii sistemului. În perspectivă, sistemul ar putea evolua către o platformă educaţională completă pentru învăţarea limbajului semnelor, integrând feedback automat şi evaluare a corectitudinii gesturilor.

6 Bibliografie

[1] Suportul de curs de la Sisteme Bazate pe Cunoaștere

[2] Materialele pentru laboratoare de la Sisteme Bazate pe Cunoaștere

[3] https://www.kaggle.com/code/aryanprakash09083/custom-cnn-model-accuracy-95-on-5-epochs/notebook

[4] https://www.kaggle.com/datasets/debashishsau/aslamerican-sign-language-aplhabet-dataset/code